

RAG 检索增强生成分为几个阶段：文档加载、文本切片、向量化存入向量库。

用户提问后，问题向量化，在向量库检索相似文本片段。

将检索到的上下文和用户问题一起送入大模型，生成答案，缓解大模型幻觉。

文本切片参数直接影响检索准确率，块太大语义混杂，块太小信息不足。

RAG 检索增强生成分为几个阶段：文档加载、文本切片、向量化存入向量库。

用户提问后，问题向量化，在向量库检索相似文本片段。

将检索到的上下文和用户问题一起送入大模型，生成答案，缓解大模型幻觉。

文本切片参数直接影响检索准确率，块太大语义混杂，块太小信息不足。